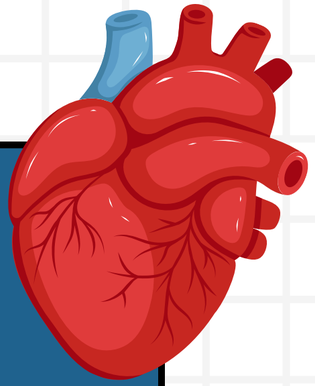
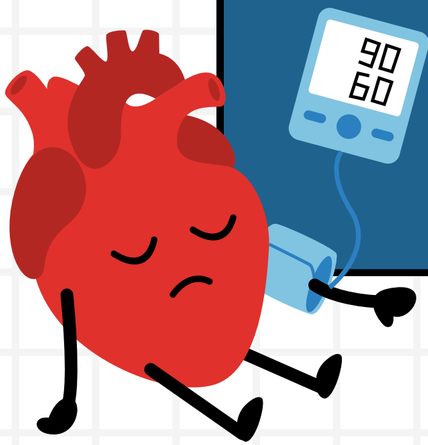


Data Preparation for Heart Disease



Project1 Group2

Project Contents

- Data Preparation
- Dataset Description
- Code Description
- Experimental Plan
- Disscuss Results

Data Preparation

Data Preparation
คือ กระบวนการ**เตรียม**และ**ปรับปรุง**ข้อมูลก่อนนำไปสร้าง Model เพื่อให้ข้อมูลมีความเหมาะสมต่อการวิเคราะห์และการเรียนรู้ของ Model โดยมีวัตถุประสงค์เพื่อลดปัญหาที่อาจส่งผลต่อประสิทธิภาพของ Model

วิธีการเตรียมข้อมูลที่สามารถนำมาใช้ได้ แบ่งออกเป็น 2 หัวข้อ

1. **Data Quality**
2. **Data Preprocessing**



Data Preparation

Data Quality

คือ การ**ตรวจสอบ**และ**แก้ไข**ปัญหาที่ทำให้ข้อมูล ไม่สมบูรณ์

3 ปัญหาหลัก:

- **Missing Values**
- **Outliers**
- **Duplicate Data**

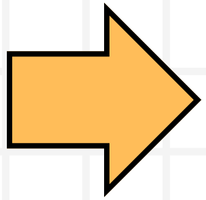
Data Preprocessing

คือ การ**ปรับเปลี่ยน**ข้อมูลให้อยู่ในรูปแบบที่ **เหมาะสม**ต่อการนำเข้า Model

วิธีที่สามารถนำมาใช้ได้:

- **Aggregation**
- **Sampling**
- **Dimensionality Reduction**
- **Feature Subset Selection**
- **Feature Transformation**

Project Contents



Data Preparation

Dataset Description

Code Description

Experimental Plan

Disscuss Results

จำนวนข้อมูล

(305,14)

Dataset

	Age	Sex	ChestPain	RestBP	Chol	Fbs	RestECG	MaxHR	ExAng	Oldpeak	Slope	Ca	Thal	AHD
1	63	1	typical	145.0	233.0	1	2	150.0	0	2.3	3	0.0	fixed	No
2	67	1	asymptomatic	160.0	286.0	0	2	108.0	1	1.5	2	3.0	normal	Yes
3	67	1	asymptomatic	120.0	229.0	0	2	129.0	1	2.6	2	2.0	reversable	Yes
4	37	1	nonanginal	130.0	250.0	0	0	187.0	0	3.5	3	0.0	normal	No
5	41	0	nontypical	130.0	204.0	0	2	172.0	0	1.4	1	0.0	normal	No

Variables	Types	meaning
Age	Numerical	อายุของผู้ป่วย
Sex	Numerical	เพศของผู้ป่วย
ChestPain	Categorical	อาการเจ็บหน้าอก
RestBP	Numerical	ความดันโลหิตขณะพัก
Chol	Numerical	ระดับคอเลสเตอรอล

จำนวนข้อมูล

(305,14)

Dataset

	Age	Sex	ChestPain	RestBP	Chol	Fbs	RestECG	MaxHR	ExAng	Oldpeak	Slope	Ca	Thal	AHD
1	63	1	typical	145.0	233.0	1	2	150.0	0	2.3	3	0.0	fixed	No
2	67	1	asymptomatic	160.0	286.0	0	2	108.0	1	1.5	2	3.0	normal	Yes
3	67	1	asymptomatic	120.0	229.0	0	2	129.0	1	2.6	2	2.0	reversable	Yes
4	37	1	nonanginal	130.0	250.0	0	0	187.0	0	3.5	3	0.0	normal	No
5	41	0	nontypical	130.0	204.0	0	2	172.0	0	1.4	1	0.0	normal	No

Variables	Types	meaning
Fbs	Numerical	ระดับน้ำตาลในเลือดขณะอดอาหาร
RestECG	Numerical	ผลการตรวจคลื่นไฟฟ้าหัวใจขณะพัก
MaxHR	Numerical	อัตราการเต้นของหัวใจสูงสุด
ExAng	Numerical	อาการเจ็บหน้าอกจากการออกกำลังกาย
Oldpeak	Numerical	ภาวะ ST segment depression

จำนวนข้อมูล

(305,14)

Dataset

	Age	Sex	ChestPain	RestBP	Chol	Fbs	RestECG	MaxHR	ExAng	Oldpeak	Slope	Ca	Thal	AHD
1	63	1	typical	145.0	233.0	1	2	150.0	0	2.3	3	0.0	fixed	No
2	67	1	asymptomatic	160.0	286.0	0	2	108.0	1	1.5	2	3.0	normal	Yes
3	67	1	asymptomatic	120.0	229.0	0	2	129.0	1	2.6	2	2.0	reversable	Yes
4	37	1	nonanginal	130.0	250.0	0	0	187.0	0	3.5	3	0.0	normal	No
5	41	0	nontypical	130.0	204.0	0	2	172.0	0	1.4	1	0.0	normal	No

Variables	Types	meaning
Slope	Numerical	ความชันของกราฟ ST segment
Ca	Numerical	จำนวนหลอดเลือดหลักที่ตรวจพบความผิดปกติ
Thal	Categorical	ความผิดปกติของธาลัสซีเมียหรือการไหลเวียนเลือด
AHD	Categorical	สถานะโรคหัวใจ **(Target output)**

จำนวนข้อมูล

(305,14)

Dataset

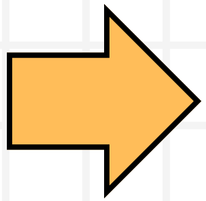
```
Missing values:
Age          0
Sex          0
ChestPain    0
RestBP       7
Chol        23
Fbs          0
RestECG      0
MaxHR        6
ExAng        0
Oldpeak      0
Slope        0
Ca           4
Thal         2
AHD          0
dtype: int64
Number of duplicates: 2
```

พบ Missing Values อยู่หลาย Features ได้แก่ RestBP, Chol, MaxHR, Ca และ Thal

รวมทั้งหมด 42 ค่า

พบ Duplicate Datas อยู่ 2 ตัว

Project Contents



Data Preparation

Dataset Description

Code Description

Experimental Plan

Disscuss Results

Code Description

Python Libraries
ที่เกี่ยวข้องกับการจัดการข้อมูล
และการสร้าง Model

```python
import pandas as pd
import numpy as np

from sklearn import preprocessing as pre
import sklearn.model_selection as ms
from sklearn.linear_model import LogisticRegression
```

Library

1. **Pandas**: อ่านและจัดการ Dataset ในรูปแบบ DataFrame
2. **NumPy**: แปลงและจัดการข้อมูล ในรูปแบบ Array
3. **Scikit-learn**: สำหรับ Data Preprocessing, Train/Test Split, Logistic Regression

```python
# Read the Heart Disease Dataset
df = pd.read_csv('project1_heart.csv', index_col=0)
```

ใช้ **read_csv** สำหรับอ่านไฟล์ .csv

Code Description

Encoding

```
# Cleaning

# One-Hot Encoding
# Convert categorical features into numerical dummy variables
# เปลี่ยน categorical ตัวแปร chestpain,Thal,ADH

df = pd.get_dummies(df, columns=['ChestPain', 'Thal', 'AHD'], drop_first=True)  # แปลงข้อมูล categorical
df = df.astype(float)  # แปลงข้อมูลทุกคอลัมน์ใน DataFrame ให้เป็นชนิดข้อมูลแบบทศนิยม (float)

cols = [c for c in df.columns if c != 'AHD_Yes'] + ['AHD_Yes']  # จัดเรียงลำดับคอลัมน์ใหม่โดยย้ายคอลัมน์ AHD_Ye
df = df[cols]  # อัปเดต DataFrame ให้ใช้ลำดับคอลัมน์ใหม่ที่จัดเรียงแล้ว

print(df.shape)  # แสดงขนาดของ DataFrame (จำนวนแถว, จำนวนคอลัมน์)
# แสดงข้อมูลตัวอย่างของ DataFrame
display(df.head())
```

ใช้ One-Hot Encoding
เพื่อแปลง Categorical Features
ให้อยู่ในรูปแบบตัวเลขก่อนนำเข้าสู่ Model

โดย 1 หมวด = 1 feature และ
1 หมายความว่ามีลักษณะนั้น
0 คือไม่มีลักษณะนั้น

```
หลังลบ Duplicate เหลือ 303 แถว
Duplicates after cleaning: 0
```

	Age	Sex	RestBP	Chol	Fbs	RestECG	MaxHR	ExAng	Oldpeak	Slope	Ca	ChestPain_nonanginal	ChestPain_nontypical	ChestPain_typical	Thal_normal	Thal_reversable	AHD_Yes
0	63.0	1.0	145.0	233.0	1.0	2.0	150.0	0.0	2.3	3.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0
1	67.0	1.0	160.0	286.0	0.0	2.0	108.0	1.0	1.5	2.0	3.0	0.0	0.0	0.0	1.0	0.0	1.0
2	67.0	1.0	120.0	229.0	0.0	2.0	129.0	1.0	2.6	2.0	2.0	0.0	0.0	0.0	0.0	1.0	1.0
3	37.0	1.0	130.0	250.0	0.0	0.0	187.0	0.0	3.5	3.0	0.0	1.0	0.0	0.0	1.0	0.0	0.0
4	41.0	0.0	130.0	204.0	0.0	2.0	172.0	0.0	1.4	1.0	0.0	0.0	1.0	0.0	1.0	0.0	0.0

```
(303, 17)
```

จำนวนข้อมูล
(303,17)

Code Description

2 วิธีในการจัดการ Missing Values

1 dropna

```python
# Remove observations containing missing values
df_exp = df.dropna().reset_index(drop=True)
```

ใช้ **dropna** ลบตัวอย่าง
ที่มี Missing Values ออก

2 fillna

```python
# Impute missing values in numerical features using the median
for col in numerical_cols:
    df_exp[col] = df_exp[col].fillna(df_exp[col].median())

# Impute missing values in categorical features using the mode
for col in categorical_cols:
    df_exp[col] = df_exp[col].fillna(df_exp[col].mode()[0])
```

ใช้ **fillna** แทนค่าที่หายไปใน โดย
ใช้ **Median** กับ
Numerical Features
ใช้ **Mode** กับ
Categorical Features

Code Description

2 วิธีในการทำ Feature Scaling

1 **Standardization**

StandardScaler(): ปรับข้อมูลให้มี Mean เท่ากับ 0 และ Standard Deviation เท่ากับ 1

2 **Normalization**

MinMaxScaler(): ปรับข้อมูลให้อยู่ในช่วง 0 ถึง 1

Code Description

RFE (Wrapper Method)

ใช้ Logistic Regression เป็น Model ในการประเมินความสำคัญของ Features และคัดเลือก Features ที่เหมาะสม

1 **rfe.fit(x_train, y_train)**

ทำ Feature Selection จาก Training Data เท่านั้น

2 **rfe.support_**

ระบุ Features ที่ถูกเลือก

3 **n_features_to_select**

กำหนดจำนวน Features ที่ต้องการเลือก คือ 13 และ 9 Features

Project Contents

Data Preparation

Dataset Description

Code Description

Experimental Plan

Disscuss Results

Experimental Design

จากการ Explore data

- พบ **Missing Values** อยู่ในหลาย Features
- **Numerical Features** มี หน่วยและ**ช่วงค่าที่แตกต่างกันมาก**

ดังนั้นจึงต้องการเปรียบเทียบการจัดการ:

Missing Values และ Feature Scaling

Round1

Objective

เพื่อเปรียบเทียบผลของการจัดการ
Missing Values และ **Feature Scaling** ในรูปแบบต่าง ๆ
ต่อ **Performance** ของ Model
และ **หา Data Preparation ที่เหมาะสมที่สุดกับชุดข้อมูลนี้**

Round1

Hypothesis

การจัดการ **Missing Values** ด้วย **Median/Mode Imputation**
ร่วมกับการทำ **Feature Scaling** ด้วย **Standardization**
จะให้ **Performance ในการทำนายดีที่สุด**สำหรับชุดข้อมูลนี้

Experimental Design

จัดการ Missing Value ด้วยวิธี "**Drop**"

ร่วมกับเทคนิค Scaling 3 แบบ:

1. Without Scaling ➔ Experiment 1
2. Standardization ➔ Experiment2
3. Normalization ➔ Experiment 3

จัดการ Missing Value ด้วยวิธี "**Median/Mode Imputation**"

ร่วมกับเทคนิค Scaling 3 แบบ:

1. Without Scaling ➔ Experiment 4
2. Standardization ➔ Experiment 5
3. Normalization ➔ Experiment 6

ดังนั้นจะเกิดการทดลองทั้งหมด 6 Experiments

Experimental Design

Experiment	Missing Value Handling	Scaling Method
Experiment1	Drop	No Scaling
Experiment2	Drop	Standardization
Experiment3	Drop	Normalization
Experiment4	Median/Mode Imputation	No Scaling
Experiment5	Median/Mode Imputation	Standardization
Experiment6	Median/Mode Imputation	Normalization

Experimental Results

Experiment	Missing Value Handling	Scaling Method	Training Performance	Testing Performance
Experiment1	Drop	No Scaling	89.94%	80.90%
Experiment2	Drop	Standardization	90.50%	80.90%
Experiment3	Drop	Normalization	87.15%	84.27%
Experiment4	**Median/Mode Imputation**	**No Scaling**	**87.19%**	**86.00%**
Experiment5	**Median/Mode Imputation**	**Standardization**	**86.21%**	**86.00%**
Experiment6	Median/Mode Imputation	Normalization	86.70%	85.00%

Experimental Results

Experiment	Missing Value Handling	Scaling Method	Training Performance	Testing Performance	Gap (Train-Test)
Experiment1	Drop	No Scaling	89.94%	80.90%	9.94%
Experiment2	Drop	Standardization	90.50%	80.90%	9.60%
Experiment3	Drop	Normalization	87.15%	84.27%	2.88%
Experiment4	Median/Mode Imputation	No Scaling	87.19%	**86.00%**	**1.19%**
Experiment5	**Median/Mode Imputation**	**Standardization**	**86.21%**	**86.00%**	**0.21%**
Experiment6	Median/Mode Imputation	Normalization	86.70%	85.00%	1.70%

Experimental Design

อยากทราบว่า การลดจำนวน Features ลง
จะทำให้ Performance ดีขึ้นได้อีกไหม

ดังนั้นจึงต้องการเปรียบเทียบระหว่าง:

ใช้ Features ทั้งหมด และ การเลือกแค่บาง Features

Round2

Objective

เพื่อเปรียบเทียบผลของการ**ลดจำนวน Features**
ด้วย Feature subset selection แบบ **Wrapper** โดยใช้ **RFE**
ต่อ **Performance** ของ Model และพิจารณาว่า
การลดจำนวน Features ลงเหมาะสมกับชุดข้อมูลนี้หรือไม่

Round2

Hypothesis

การ**ลดจำนวน Features ด้วย RFE** ร่วมกับ
Data Preparation ที่ให้ผลดีที่สุดจากการทดลองก่อนหน้า
จะ**ช่วยเพิ่ม Performance** ของ Model
เมื่อเทียบกับการใช้ Features ทั้งหมด

What is RFE?

RFE (Recursive Feature Elimination) คือ
วิธีเลือก Features แบบ Wrapper Method
โดยใช้ Logistic Regression เป็นตัวช่วยเลือก Features

หลักการทำงานของ RFE:

- เริ่มจาก Features ทั้งหมด 16 Features
- ให้ Model พิจารณาความสำคัญของแต่ละ Feature
- ตัด Feature ที่มีความสำคัญน้อยที่สุดออกทีละ 1 ตัว
- วนซ้ำจนเหลือจำนวน Features ที่กำหนด

Experimental Design

Experiment 5

- Median/Mode Imputation
- Standardization

Best Model Round1

Experiment 7

- Median/Mode Imputation
- Standardization
- RFE (Wrapper Method)

16 → 13 Features

Experiment 8

- Median/Mode Imputation
- Standardization
- RFE (Wrapper Method)

16 → 9 Features

Experimental Design

Experiment	Missing Value Handling	Scaling Method	Features Selection	จำนวน Features
Experiment 5	Median/Mode Imputation	Standardization	No	**16**
Experiment 7	Median/Mode Imputation	Standardization	RFE	**13**
Experiment 8	Median/Mode Imputation	Standardization	RFE	**9**

Experimental Results

Experiment	Missing Value Handling	Scaling Method	Features Selection	จำนวน Features	Training Performance	Testing Performance
Experiment 5	**Median/Mode Imputation**	**Standardization**	**No**	**16**	**86.21%**	**86.00%**
Experiment 7	**Median/Mode Imputation**	**Standardization**	**RFE**	**13**	**86.21%**	**86.00%**
Experiment 8	Median/Mode Imputation	Standardization	RFE	9	85.71%	84.00%

Project Contents

Data Preparation

Dataset Description

Code Description

Experimental Plan

Disscuss Results

Discuss Results

Experiment	Missing Value Handling	Scaling Method	Feature Selection	จำนวน Features	Training Performance	Testing Performance	Gap (Train-Test)
Experiment1	Drop	No Scaling	No	16	89.94%	80.90%	9.94%
Experiment2	Drop	Standardization	No	16	90.50%	80.90%	9.60%
Experiment3	Drop	Normalization	No	16	87.15%	84.27%	2.88%
Experiment4	Median/Mode Imputation	No Scaling	No	16	87.19%	**86.00%**	**1.19%**
Experiment5	**Median/Mode Imputation**	**Standardization**	**No**	**16**	**86.21%**	**86.00%**	**0.21%**
Experiment6	Median/Mode Imputation	Normalization	No	16	86.70%	85.00%	1.70%
Experiment7	**Median/Mode Imputation**	**Standardization**	**RFE**	**13**	**86.21%**	**86.00%**	**0.21%**
Experiment8	Median/Mode Imputation	Standardization	RFE	9	85.71%	84.00%	1.71%

Discussion

Missing Values

Drop vs Imputation

จากผลการทดลองพบว่า **Median/Mode Imputation** ให้ Testing Accuracy สูงกว่า **Drop** ในทั้ง 3 วิธี **Scaling**

อาจเป็นเพราะการ Drop ทำให้จำนวน instances ที่ใช้ในการสร้าง Model ลดลง ในขณะที่ Imputation **สามารถรักษาข้อมูลส่วนใหญ่ของ Dataset ไว้ได้** จึงทำให้ Model เรียนรู้รูปแบบของข้อมูลได้ดีกว่า สำหรับ Dataset นี้ที่มีขนาดเล็ก

Discussion

Feature Scaling

No Scaling vs Standardization vs Normalization

เมื่อใช้ **Median/Mode Imputation** ร่วมกับ **No Scaling** และ **Standardization** ให้ Testing Accuracy 86% ขณะที่ Normalization ให้ 85% ดังนั้น Standardization ให้ผลดีกว่า Normalization อยู่เล็กน้อยใน Dataset นี้

อาจเพราะ **Standardization** ปรับค่าตามค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน ทำให้ยังคง**รักษา pattern การกระจายของข้อมูล** ขณะที่ **Normalization** ปรับค่าตามค่าต่ำสุดและค่าสูงสุดให้อยู่ในช่วง 0–1 ซึ่งอาจ**ส่งผลต่อลักษณะการกระจายของข้อมูล**
ทำให้ Standardization เหมาะกับ Dataset นี้มากกว่า Normalization

Discussion

Feature Subset Selection

16 vs 13 vs 9

การใช้ **RFE** ลด Features จาก **16 → 13 Features** ทำให้ Testing Accuracy ยังคงเดิม แต่เมื่อลดจาก **16 → 9 Features** ค่า Testing Accuracy กลับลดลง

อาจเป็นเพราะ Features ที่ถูกตัดออกในช่วงแรก**มีข้อมูลที่ซ้ำซ้อนอยู่** จึงไม่ส่งผลต่อ Model แต่เมื่อจำนวน Features ลดลงมากขึ้น **อาจมีการตัด Features ที่มีข้อมูลสำคัญต่อการจำแนกโรคหัวใจออกไป** ทำให้ Model มีข้อมูลสำหรับการทำนายน้อยลง ส่งผลให้ performance ของ Model แย่ลง

Discussion

Overall

จากผลการทดลองทั้ง 8 Experiments พบว่า **E5 และ E7** ให้ Performance ดีที่สุดเท่ากัน โดยมี Testing Accuracy 86% และ Gap 0.21%

โดย **E5 ใช้ Features ทั้ง 16 ตัว** ขณะที่ **E7 ใช้ RFE ลด Features เหลือ 13 ตัว** และไม่ทำให้ Performance ลดลง

ดังนั้น **E7 เป็น Model ที่เหมาะสมที่สุด** เนื่องจากใช้จำนวน Features น้อยกว่า ทำให้ Model มีความซับซ้อนลดลง อาจลดภาระในการประมวลผลและการจัดเตรียมข้อมูลได้

Experiment	Missing Value Handling	Scaling Method	Feature Selection	จำนวน Features	Training Performance	Testing Performance	Gap (Train-Test)
Experiment5	Median/Mode Imputation	Standardization	No	16	86.21%	86.00%	0.21%
Experiment7	Median/Mode Imputation	Standardization	RFE	13	86.21%	86.00%	0.21%

Discussion

POV of Dataset Domain

- **Heart Disease Dataset** เป็นข้อมูลผู้ป่วยที่มีหลายปัจจัยที่เกี่ยวข้องกับโรคหัวใจ จึงต้องพิจารณาหลาย Features ร่วมกันในการจำแนกผู้ป่วย
- **Dataset มีขนาดไม่ใหญ่มาก** และมี Missing Values ในหลาย Features การใช้ Imputation จึงช่วยรักษาจำนวนข้อมูลไว้สำหรับการเรียนรู้ของ Model ได้มากกว่า
- **Features มีลักษณะและช่วงค่าที่แตกต่างกัน** ทำให้ Standardization เป็นวิธีที่เหมาะสมในการปรับ Scale ของข้อมูลก่อนสร้าง Model
- **โรคหัวใจมีหลายปัจจัยที่เกี่ยวข้องกัน การลด Features มากเกินไปอาจทำให้สูญเสียข้อมูลที่สำคัญต่อการจำแนกผู้ป่วย** ซึ่งสอดคล้องกับผล Accuracy ที่ลดลงเมื่อจำนวน Features ลดจาก 16 เหลือ 9 ตัว

BEST MODEL

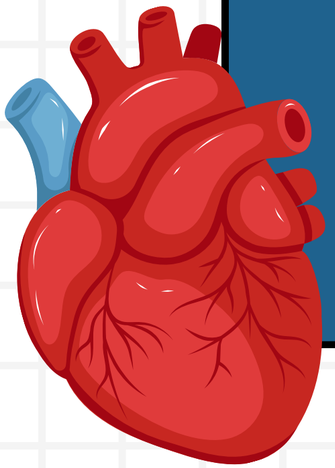
Experiment 7

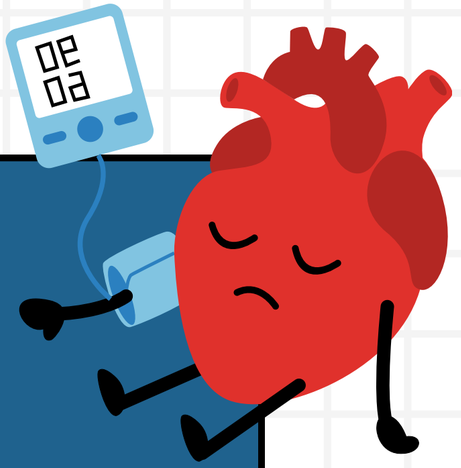
- **Missing Value**: Median/Mode Imputation
- **Scaling**: Standardization
- **Feature Subset Selection**: RFE (Wrapper Method)
  16 → 13 Features
- **Training Accuracy**: 86.21%
- **Testing Accuracy**: 86.00%

Members

1. นายนันทวัฒน์	ใจเที่ยง	: 67102010399
2. นางสาวนาขวัญ	จิตต์เอื้อเฟื้อ	: 67102010400
3. นางสาวปุณณภา	จึงเปี่ยมสุข	: 67102010401

Thanks for listening!





Project1 Group2